

Rapport Breast Cancer

kawtar hlal

03 December 2025

Ce rapport présente une analyse structurée des étapes de pré-traitement, d'exploration de données et de modélisation réalisées dans le notebook `CC.ipynb`. Le projet vise à résoudre un problème de classification binaire (statut de survie des patients) à partir de données médicales. Le modèle le plus performant identifié est le **Random Forest Classifier**, bien qu'une étape cruciale d'optimisation des hyperparamètres soit manquante.

Table des matières

1	Introduction et Objectifs du Projet	3
2	Pré-traitement des Données (<i>Preprocessing</i>)	3
2.1	Nettoyage et Imputation des Valeurs Manquantes	3
2.2	Encodage et Mise à l'Échelle	3
2.3	Gestion du Déséquilibre de Classe	3
3	Analyse Exploratoire des Données (EDA)	3
3.1	Observations Clés des Distributions	3
3.2	Analyse de Corrélation (<i>Heatmap</i>)	4
3.3	Feature Engineering	4
4	Modélisation et Résultats	4
4.1	Stratégie de Validation	4
4.2	Comparaison des Algorithmes	4
4.3	Optimisation des Hyperparamètres	4
5	Conclusion et Recommandations	4

1 Introduction et Objectifs du Projet

Le présent travail vise à évaluer et à prédire le statut de survie (**Status** : Alive/Dead) de patients à partir d'un ensemble de données contenant des caractéristiques cliniques et démographiques. Le processus d'analyse suit une méthodologie standard de Machine Learning, allant du nettoyage des données à la comparaison de multiples algorithmes.

2 Pré-traitement des Données (*Preprocessing*)

Cette section détaille les transformations appliquées aux données brutes pour les préparer à l'entraînement des modèles.

2.1 Nettoyage et Imputation des Valeurs Manquantes

- **Gestion des Doublons** : Aucune ligne en double n'a été détectée dans le jeu de données initial.
- **Standardisation** : Les valeurs des colonnes catégorielles (**Marital Status**, **Race**, **6th Stage**, **N Stage**, **T Stage**) ont été nettoyées (suppression d'espaces superflus) pour uniformiser les catégories.
- **Imputation** : Les valeurs manquantes introduites par le nettoyage des colonnes **differentiate** et **Grade** ont été imputées en utilisant la **Mode** (valeur la plus fréquente). Cette stratégie, bien que simple, a permis de compléter le jeu de données.

2.2 Encodage et Mise à l'Échelle

- **Encodage Catégoriel** : Toutes les variables catégorielles, incluant la cible **Status**, ont été transformées en valeurs numériques à l'aide du **Label Encoding** (`sklearn.preprocessing.LabelEncoder`).
- **Standardisation Numérique** : Les caractéristiques numériques (**Age**, **Grade**, **Tumor Size**, etc.) ont été mises à l'échelle via la **Standardisation** (**Z-score**) (`StandardScaler`), centrant les données autour de zéro.

2.3 Gestion du Déséquilibre de Classe

Un déséquilibre important a été noté dans la variable cible. Pour y remédier :

- La technique de suréchantillonnage **ADASYN** (**Adaptive Synthetic Sampling**) a été appliquée à l'ensemble d'entraînement.
- Cette approche génère des échantillons synthétiques pour la classe minoritaire, assurant que les modèles sont entraînés sur un ensemble de données équilibré.

3 Analyse Exploratoire des Données (EDA)

L'EDA a permis d'identifier des tendances et des corrélations cruciales.

3.1 Observations Clés des Distributions

- **Distribution d'Âge** : L'âge des patients présente une distribution relativement uniforme avec une concentration notable entre 50 et 60 ans.

- **Dominance Catégorielle** : La catégorie `Race` est très largement dominée par la valeur `'White'`.
- **Facteurs de Risque (Boxplots)** :
 - Les patients ayant un statut `'Dead'` présentent une **plus grande dispersion** et des valeurs aberrantes de `Tumor Size`.
 - Le nombre médian de `Reginol Node Positive` est significativement **plus élevé** pour le groupe `'Dead'`, indiquant une forte association avec un pronostic défavorable.

3.2 Analyse de Corrélation (*Heatmap*)

L'analyse de la matrice de corrélation a confirmé les observations visuelles :

- La variable cible `Status` est modérément corrélée positivement avec `Reginol Node Positive` et `Tumor Size`, confirmant leur importance prédictive.
- La relation négative attendue entre `Status` et `Survival Months` a été observée.

3.3 Feature Engineering

Il est à noter qu'aucune étape explicite de *Feature Engineering* (création de nouvelles variables ou d'interactions) n'a été réalisée dans le cadre de ce notebook.

4 Modélisation et Résultats

4.1 Stratégie de Validation

- Les modèles ont été évalués en utilisant la **Validation Croisée à 10 plis** (`cv=10`) via la fonction `cross_val_score`.
- Cette approche garantit une robustesse des métriques en minimisant l'impact du découpage Train/Test.

4.2 Comparaison des Algorithmes

Dix algorithmes de classification ont été testés et comparés sur la base de leur *Accuracy* moyenne en validation croisée.

Conclusion de la Modélisation : Le **Random Forest Classifier** a démontré la meilleure performance de généralisation avec une *Accuracy* de 87.6%.

4.3 Optimisation des Hyperparamètres

Statut : Aucune optimisation des hyperparamètres (*e.g.*, utilisation de `GridSearchCV` ou `RandomizedSearchCV`) n'a été effectuée pour les modèles testés. Les performances rapportées sont donc basées sur les configurations par défaut ou manuelles.

5 Conclusion et Recommandations

L'analyse a identifié le **Random Forest Classifier** comme le modèle le plus prometteur. Les facteurs `Reginol Node Positive` et `Tumor Size` sont les prédicteurs les plus influents.

TABLE 1 – Résultats de l'Accuracy Moyenne en Cross-Validation

Algorithme	Accuracy Moyenne (CV)	Type de Modèle
Random Forest Classifier	0.876	Ensemble
XGBoost Classifier	0.863	Boosting (Arbres)
Decision Tree Classifier	0.824	Arbre de Décision
K-Nearest Neighbors (KNN)	0.820	Basé sur la Distance
Gradient Boosting Classifier	0.775	Boosting (Arbres)
Multi-layer Perceptron (MLP)	0.751	Réseau de Neurones
Logistic Regression	0.722	Linéaire
Support Vector Classifier (SVC)	0.711	Basé sur les Marges
Gaussian Naive Bayes	0.677	Probabiliste
Multinomial Naive Bayes	0.620	Probabiliste

Pour améliorer et finaliser le projet, les recommandations suivantes sont formulées :

1. **Optimisation des Hyperparamètres** : Exécuter une recherche d'hyperparamètres (avec `GridSearchCV`) sur les meilleurs modèles (Random Forest et XGBoost) pour maximiser l'Accuracy.
2. **Évaluation Complémentaire** : Évaluer les modèles avec des métriques sensibles au déséquilibre (F1-Score, AUC, Précision/Rappel) pour valider l'efficacité d'ADASYN.
3. **Feature Engineering** : Explorer la création de variables d'interaction pour potentiellement augmenter le pouvoir prédictif des modèles.